



Human-Centered Data & AI

Vinicius Caridá, Ph.D.



Data Science Manager, Itaú Unibanco

MBA Professor, FIAP

GDE – Machine Learning



@vinicius caridá



@vfcarida



@vinicius caridá



@vfcarida



@vinicius caridá



@vfcarida

“

SVM

Support Vector Machine

SVM | Support Vector Machine


- Proposto em 79 por Vladimir Vapnik
- Um dos mais importantes acontecimentos na área de reconhecimento de padrões nos últimos 15 anos.
- Tem sido largamente utilizado com sucesso para resolver diferentes problemas.




SVM | Support Vector Machine

- É um algoritmo de aprendizado de máquina supervisionado que é utilizado, principalmente, para problemas de classificação mas também pode ser usado para regressão (SVR); <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html>
- Com a existência de duas ou mais classes rotuladas de dados, ele age como um classificador discriminativo, formalmente definido por um hiperplano ideal que separa todas as classes;
- Novos exemplos que são então mapeados para o mesmo espaço podem ser categorizados com base em qual lado da lacuna eles se encontram.


SVM | Support Vector Machine




SVM | Support Vector Machine



SVM | Support Vector Machine



SVM | Support Vector Machine




SVM | Support Vector Machine




SVM | Support Vector Machine

Qual linha é melhor?





SVM | Support Vector Machine

Qual a fronteira que deve ser escolhida??



SVM | Support Vector Machine

Qual a fronteira que deve ser escolhida??





Como a linha está bem próxima da classe azul, seu **poder de generalização é baixo**

Note que um novo elemento (dados não usados no treinamento), bem próximo de um azul será classificado erroneamente.


SVM | Support Vector Machine

Qual a fronteira que deve ser escolhida??



Como a linha está bem próxima da classe azul, seu **poder de generalização é baixo**

Note que um novo elemento (dados não usados no treinamento), bem próximo de um azul será classificado erroneamente.




Podemos notar que o poder de generalização é bem melhor.

Novos dados são corretamente classificados, pois temos uma fronteira mais distante dos dados de treinamento.


SVM | Support Vector Machine

- O conceito por trás do SVM é a maximização da margem, ou seja, maximizar a distância da margem dos dados de treinamento




SVM | Support Vector Machine

Qual linha é melhor?




SVM | Support Vector Machine




SVM | Support Vector Machine

- Os vetores de suporte são os pontos de dados mais próximos do hiperplano; os pontos de um conjunto de dados que, se removidos, alterariam a posição do hiperplano divisor;
- Por causa disso, eles podem ser considerados os elementos críticos de um conjunto de dados, são eles que nos ajudam a construir nosso SVM.



SVM | Support Vector Machine

Como separar as linhas?



$$.2x + .3y + (-.6) = 0$$



$$2x + 3y + (-6) = 0$$

$$4x + 6y + (-12) = 0$$

$$20x + 30y + (-60) = 0$$



SVM | Support Vector Machine

Como separar as linhas?




SVM | Support Vector Machine

Como separar as linhas?




SVM | Support Vector Machine

Como separar as linhas?




SVM | Support Vector Machine

Como separar as linhas?





SVM | Support Vector Machine

Qual linha é melhor?



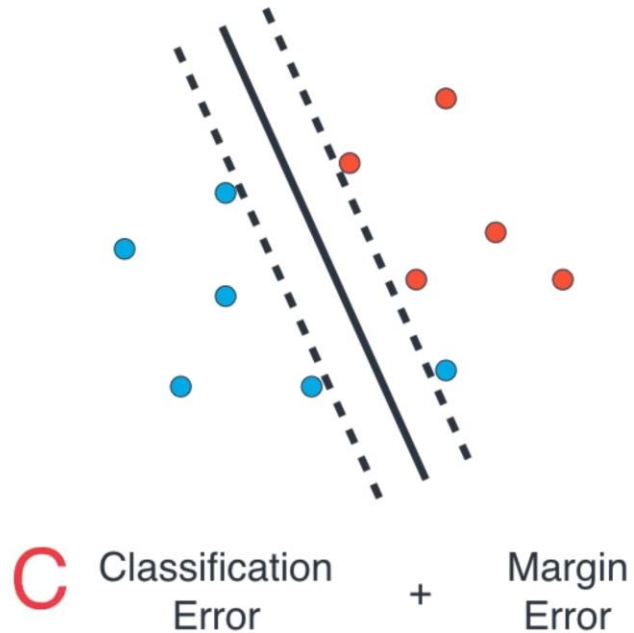
SVM | Support Vector Machine

Qual linha é melhor?




SVM | Support Vector Machine

The C parameter



SVM | Support Vector Machine


Qual linha é melhor?



$$C \text{ Classification Error} + \text{Margin Error}$$

SVM | Support Vector Machine

Qual linha é melhor?

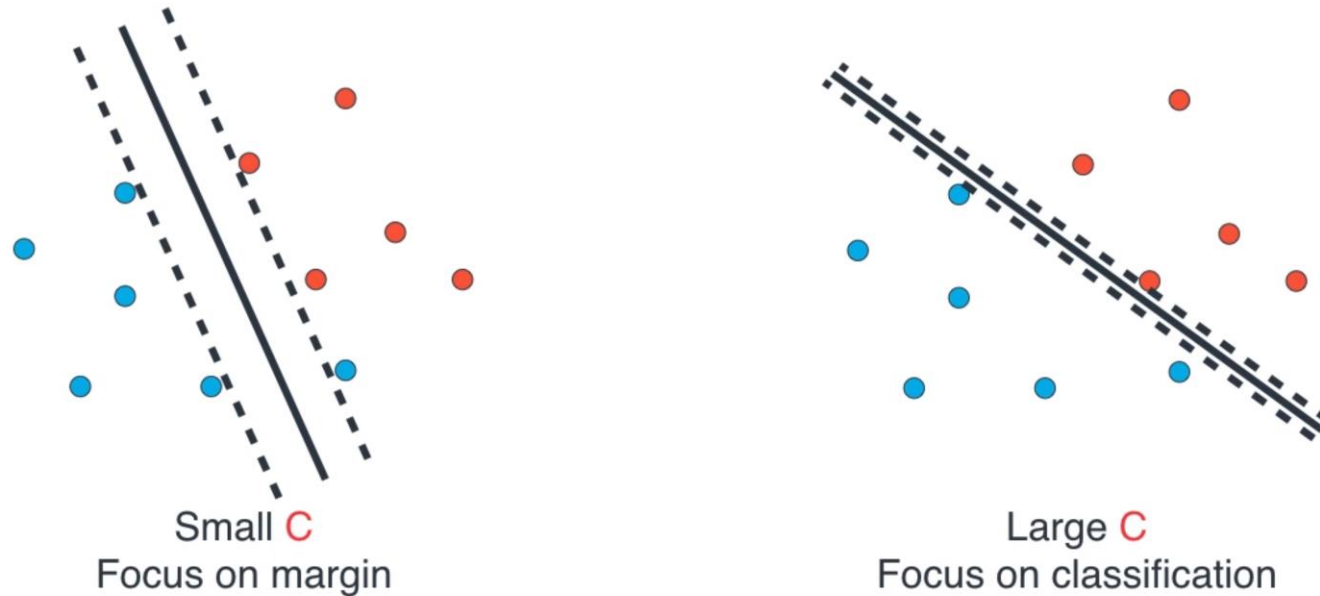


$$\text{Classification Error} + \text{Margin Error}$$

The diagram shows the SVM cost function as the sum of Classification Error and Margin Error. The Classification Error term is crossed out with a red 'X', indicating it is not the primary focus for small C. The Margin Error term is highlighted with a green border, indicating it is the primary focus for small C.

SVM | Support Vector Machine

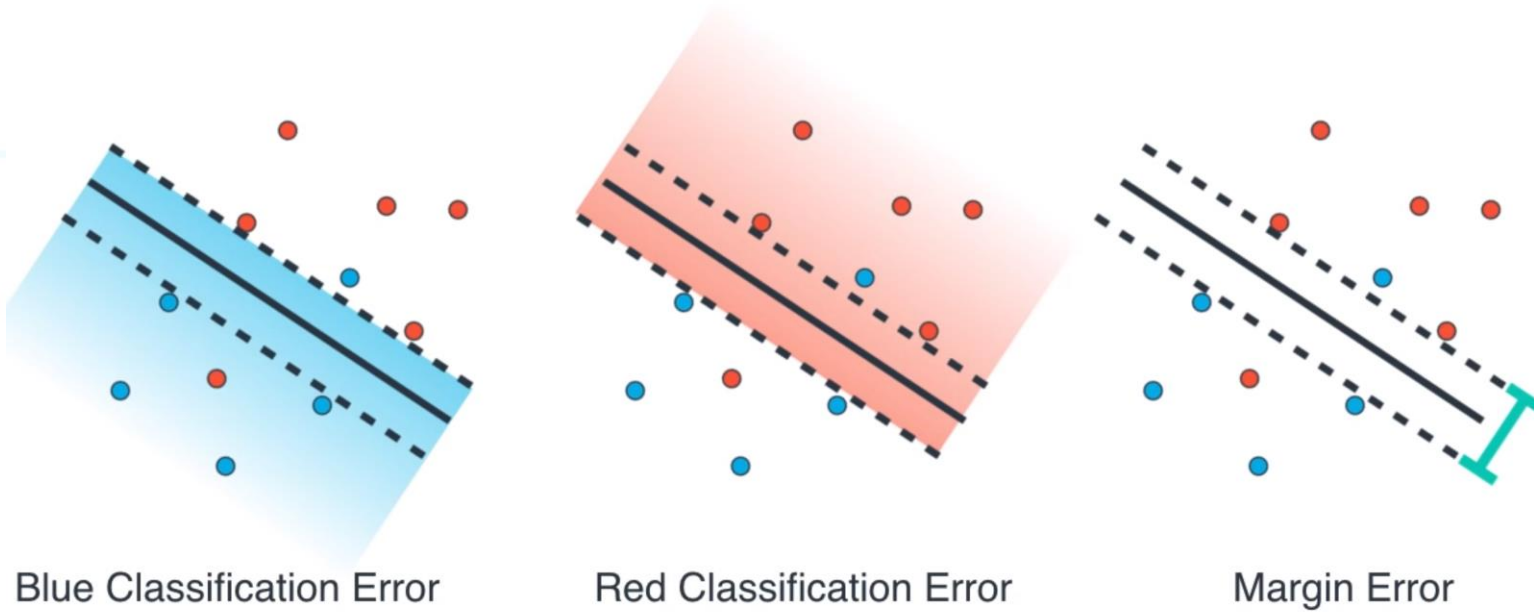
Qual linha é melhor?



$$C \text{ Classification Error} + \text{Margin Error}$$


SVM | Support Vector Machine

SVM Error




SVM | Support Vector Machine

SVM Error




Classification Error



Margin Error

SVM | Support Vector Machine


SVM Error



SVM | Support Vector Machine

- A grande maioria dos problemas reais não são linearmente separáveis.
- A pergunta então é: “Como resolver problemas que não são linearmente separáveis com um classificador linear?”

Projetar os dados em um espaço onde os dados são linearmente separáveis.




SVM | Support Vector Machine




SVM | Support Vector Machine




SVM | Support Vector Machine





SVM | Support Vector Machine



$$x = [x, x^2]$$


$$1 = [1, 1]$$

$$-1 = [-1, 1]$$


SVM | Support Vector Machine

- A geometria nos diz que um hiperplano é um subespaço de uma dimensão menor que seu espaço de ambiente; Por exemplo, um hiperplano de um espaço n -dimensional é um subconjunto plano com dimensão $n-1$;
- Simplificando, é como se um hiperplano separasse o espaço em dois meios espaços (classificador binário).

A hyperplane in \mathbb{R}^2 is a line



A hyperplane in \mathbb{R}^3 is a plane



A hyperplane in \mathbb{R}^n is an $n-1$ dimensional subspace

SVM | Support Vector Machine



$$f(x) = \sum_i \alpha_i y_i K(x, x_i) + b$$

- A função de decisão pode ser descrita pela fórmula acima, na qual:
 - K é a função de kernel,
 - α e b são os parâmetros encontrados durante o treinamento,
 - x_i e y_i são os vetores de características e o *label* da classe respectivamente.

SVM | Support Vector Machine

$$\begin{aligned}\phi: \mathbb{R}^2 &\longrightarrow \mathbb{R}^3 \\ (x_1, x_2) &\longmapsto (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)\end{aligned}$$


 $\Phi: \mathbf{x} \rightarrow \boldsymbol{\varphi}(\mathbf{x})$



“

SVM

Anexos

SVM | Support Vector Machine

Considere que o conjunto de treinamento $\{(\mathbf{x}_i, y_i)\}_{i=1..N}$, $\mathbf{x}_i \in \mathbf{R}^d$, $y_i \in \{-1, 1\}$, seja separado por um hiperplano de margem ρ . Então para cada (\mathbf{x}_i, y_i) temos:

$$\begin{aligned} \mathbf{w}^T \mathbf{x}_i + b &\leq -\rho/2 & \text{se } y_i = -1 \\ \mathbf{w}^T \mathbf{x}_i + b &\geq \rho/2 & \text{se } y_i = 1 \end{aligned} \Leftrightarrow y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq \rho/2$$

Para cada \mathbf{x}_s a inequação acima se torna uma equação. Após reescalar \mathbf{w} e b por $\rho/2$ na equação, a distância entre cada \mathbf{x}_s e o hiperplano é:

$$r = \frac{y_s(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

Então a margem pode ser expressa por meio de \mathbf{w} e b como:

$$\rho = 2r = \frac{2}{\|\mathbf{w}\|}$$

SVM | Support Vector Machine

Então podemos formular o problema de otimização quadrática:

Encontrar \mathbf{w} e b tal que

seja maximizado

e para todos os $(\mathbf{x}_i, y_i), i=1..N$: $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$

Este pode ser reformulado como:

Encontrar \mathbf{w} e b tal que

$\Phi(\mathbf{w}) = \|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w}$ seja minimizado


E para todo $(\mathbf{x}_i, y_i), i=1..N$: $y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1$

SVM | Support Vector Machine

- Problema de otimização passa então a ser:

Encontrar \mathbf{w} e b tal que
 $\Phi(\mathbf{w}) = \mathbf{w}^T \mathbf{w} + C \sum \xi_i$ é minimizado
e para todo $(\mathbf{x}_i, y_i), i=1..N: y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0$

- O parâmetro C é útil para controlar o superajuste (*overfitting*), balanceando a importância relativa de maximizar a margem e ajustá-la aos dados de treinamento.
- Escolher C via validação cruzada.



SVM | Support Vector Machine

Algumas opções de kernels:

Kernel	Inner Product Kernel
Linear	$K(x, y) = (x \cdot y)$
Gaussian	$K(x, y) = \exp\left(-\frac{\ x - x_i\ ^2}{2\sigma^2}\right)$
Polynomial	$K(x, y) = (x \cdot y)^p$
Tangent Hyperbolic	$K(x, y) = \tanh(x \cdot y - \Theta)$

- Escolher aquele que se ajusta melhor aos dados: fronteiras de decisão podem requerer kernels complexos;
- Maximizar a margem → pesos → vetores

Thanks !



Vinicius Fernandes Caridá

vfcarida@gmail.com



@vinicius caridá



@vfcarida



@vinicius caridá



@vfcarida



@vinicius caridá



@vfcarida